

Laboratório 03 - Caracterizando a atividade de code review no github

Lucas Flor Vilela

`lucas.vilela@sga.pucminas.br`

Marina Ferreira Sansão Cabalzar

`marina.cabalzar@sga.pucminas.br`

May 8, 2026

Repositório do projeto

1 Introdução

A prática de code review tem se consolidado como uma etapa essencial nos processos modernos de desenvolvimento de software, especialmente em ambientes colaborativos e ágeis [Bacchelli e Bird 2013]. Essa prática consiste na análise do código produzido por desenvolvedores antes de sua integração à base principal do projeto, com o objetivo de identificar possíveis defeitos, garantir a aderência a padrões de qualidade e promover a troca de conhecimento entre os membros da equipe [Goues et al. 2019]. No contexto de projetos open source hospedados no GitHub, o code review ocorre, principalmente, por meio da avaliação de Pull Requests (PRs), nos quais contribuições são submetidas e discutidas antes de serem aceitas (merge) ou rejeitadas (closed) [GitHub 2026].

Diante desse cenário, compreender os fatores que influenciam o resultado de um Pull Request torna-se fundamental tanto para desenvolvedores que desejam aumentar a aceitação de suas contribuições quanto para equipes que buscam otimizar seus processos de revisão. Aspectos como o tamanho da alteração proposta, o tempo necessário para análise, a qualidade da descrição e o nível de interação entre os participantes podem impactar diretamente na decisão final sobre o PR [Tsay, Dabbish e Herbsleb 2014]. Assim, este trabalho tem como objetivo analisar a atividade de code review em repositórios populares do GitHub, buscando identificar relações entre diferentes características dos PRs e seus resultados, bem como o número de revisões realizadas.

1.1 Problema de Pesquisa

O problema de pesquisa deste estudo consiste em entender **quais fatores estão associados ao sucesso ou rejeição de Pull Requests em projetos open**

source, além de identificar quais características influenciam a quantidade de revisões realizadas durante o processo de code review. Estudos anteriores indicam que fatores técnicos e sociais podem impactar diretamente a avaliação de contribuições em plataformas como o GitHub [Tsay, Dabbish e Herbsleb 2014, Kononenko et al. 2016].

Em outras palavras, busca-se investigar de que forma atributos mensuráveis dos PRs, como tamanho, tempo de análise, descrição e interações, impactam tanto o feedback final quanto a dinâmica de revisão, contribuindo para uma melhor compreensão desse processo amplamente utilizado no desenvolvimento colaborativo [Bacchelli e Bird 2013].

1.2 Hipóteses

Com base no contexto apresentado e em estudos anteriores sobre code review e análise de Pull Requests [Bacchelli e Bird 2013, Tsay, Dabbish e Herbsleb 2014], são formuladas as seguintes hipóteses para orientar a análise dos dados:

- **H01: Pull Requests de maior tamanho tendem a ter menor probabilidade de aprovação, devido ao maior esforço necessário para revisão** [Bacchelli e Bird 2013].
- **H02: Pull Requests com maior tempo de análise tendem a receber mais revisões, indicando maior complexidade** [Kononenko et al. 2016].
- **H03: Pull Requests com descrições mais detalhadas tendem a ter maior probabilidade de aprovação, por facilitarem o entendimento da proposta** [Tsay, Dabbish e Herbsleb 2014].
- **H04: Pull Requests com maior número de interações (comentários e participantes) tendem a passar por revisões mais rigorosas, podendo impactar tanto o número de revisões quanto o resultado final** [Kononenko et al. 2016].

2 Metodologia

Esta seção descreve os procedimentos adotados para a coleta, tratamento e análise dos dados, com o objetivo de responder às questões de pesquisa propostas.

2.1 Criação do Dataset

O dataset utilizado neste estudo foi composto por Pull Requests (PRs) extraídos de repositórios populares do GitHub. O uso de dados provenientes do GitHub é amplamente adotado em estudos empíricos na área de Engenharia de Software, devido à disponibilidade e riqueza de informações [Kalliamvakou et al. 2014]. Foram considerados apenas repositórios com elevado número de contribuições, garantindo maior relevância e diversidade dos dados analisados.

Para a seleção dos PRs, foram aplicados os seguintes critérios:

- PRs com status MERGED ou CLOSED;
- PRs com pelo menos uma revisão registrada;
- PRs cujo tempo de análise (diferença entre criação e fechamento/merge) seja superior a uma hora, a fim de desconsiderar revisões automatizadas;
- Além disso, foram considerados apenas repositórios com no mínimo 100 PRs, garantindo consistência estatística na análise.

2.2 Coleta de Dados

A coleta dos dados foi realizada por meio de um script automatizado utilizando a API do GitHub, permitindo a extração das informações relevantes de cada Pull Request. O uso de dados provenientes do GitHub é amplamente adotado em estudos empíricos na área de Engenharia de Software, devido à sua disponibilidade e riqueza de informações [Kalliamvakou et al. 2014].

Entre os dados coletados, destacam-se informações relacionadas ao tamanho, tempo de análise, descrição e interações associadas aos PRs, métricas frequentemente utilizadas na análise de processos de code review [Tsay, Dabbish e Herbsleb 2014].

2.3 Métricas Utilizadas

Para a análise dos dados, foram definidas métricas organizadas em quatro dimensões principais, com base em estudos relacionados à análise de Pull Requests e processos de code review [Tsay, Dabbish e Herbsleb 2014, Kononenko et al. 2016]:

- **M01 – Tamanho:** número de arquivos modificados e quantidade de linhas adicionadas e removidas;
- **M02 – Tempo de Análise:** intervalo entre a criação do PR e sua última atividade (merge ou fechamento);
- **M03 – Descrição:** quantidade de caracteres presentes na descrição do PR;
- **M04 – Interações:** número de participantes e quantidade de comentários associados ao PR.

Essas métricas foram utilizadas para investigar sua relação com o feedback final dos PRs e com o número de revisões realizadas, aspectos frequentemente analisados na literatura de engenharia de software [Bacchelli e Bird 2013].

2.4 Questões de Pesquisa

Com base nas métricas definidas e em estudos relacionados à análise de Pull Requests e code review [Tsay, Dabbish e Herbsleb 2014, Bacchelli e Bird 2013], foram elaboradas as seguintes questões de pesquisa:

- **RQ01:** Qual a relação entre o tamanho dos PRs e o feedback final das revisões?
- **RQ02:** Qual a relação entre o tempo de análise dos PRs e o feedback final das revisões?
- **RQ03:** Qual a relação entre a descrição dos PRs e o feedback final das revisões?
- **RQ04:** Qual a relação entre as interações nos PRs e o feedback final das revisões?
- **RQ05:** Qual a relação entre o tamanho dos PRs e o número de revisões realizadas?
- **RQ06:** Qual a relação entre o tempo de análise dos PRs e o número de revisões realizadas?
- **RQ07:** Qual a relação entre a descrição dos PRs e o número de revisões realizadas?
- **RQ08:** Qual a relação entre as interações nos PRs e o número de revisões realizadas?

2.5 Técnicas Utilizadas

Para analisar as relações entre as métricas e as variáveis de interesse, foi utilizado um teste de correlação estatística. Considerando que os dados podem não seguir uma distribuição normal e podem conter outliers, optou-se pelo uso do coeficiente de correlação de Spearman, que avalia relações monotônicas entre variáveis [Field 2013].

Além disso, foram utilizados valores de mediana para sumarização dos dados, conforme recomendado na literatura estatística, garantindo maior robustez frente a possíveis valores extremos [Field 2013].

2.6 Fluxograma Metodologia

A Figura 1 apresenta o fluxograma da metodologia adotada neste estudo, conforme modelado no diagrama em PlantUML. O processo inicia-se com a definição dos objetivos, seguida pela coleta e extração dos dados dos Pull Requests por meio da API do GitHub. Em seguida, é realizada a criação do dataset com a aplicação de critérios de filtragem. Posteriormente, são definidas as métricas e formuladas as questões de pesquisa. Por fim, os dados são tratados e analisados

com o uso de técnicas estatísticas, permitindo a interpretação dos resultados e a resposta às questões propostas.




Figure 1: Fluxo de Metodologia

3 Resultados

Nesta seção, apresentamos os resultados extraídos do dataset coletado. Para responder às questões da Dimensão A (Feedback Final), resumizamos os dados utilizando a mediana, uma medida de tendência central robusta contra *out-

liers*. Para verificar se a diferença entre os PRs aprovados (MERGED) e rejeitados (CLOSED) é estatisticamente válida, aplicamos o teste não paramétrico U de Mann-Whitney, com um nível de significância de 5% ($p < 0,05$).

3.1 RQ01 - Tamanho X Feedback Final

Para avaliar a relação entre o tamanho das contribuições e o status final do Pull Request, analisamos três métricas: número de arquivos alterados, linhas adicionadas e linhas removidas.

Os dados revelaram que os PRs integrados com sucesso (MERGED) possuem medianas ligeiramente maiores em todas as métricas de tamanho quando comparados aos PRs rejeitados (CLOSED). A mediana de arquivos modificados foi de 2,0 para PRs aprovados contra 1,0 para rejeitados. Em relação ao volume de código, os PRs com status MERGED apresentaram uma mediana de 18,0 linhas adicionadas e 4,0 linhas removidas, enquanto os PRs com status CLOSED registraram 17,0 e 1,0 linhas, respectivamente.

O teste U de Mann-Whitney confirmou que todas as três diferenças são estatisticamente significativas ($p < 0,05$). De forma contraintuitiva, os resultados indicam que, no ecossistema analisado, PRs que acabam sendo aprovados tendem a ser marginalmente maiores do que aqueles que são rejeitados ou abandonados.




Figure 2: Distribuição de Linhas Adicionadas por Status do PR

3.2 RQ02 - Tempo X Feedback Final

Esta questão de pesquisa investiga de que forma o tempo decorrido entre a criação do Pull Request e a sua conclusão (seja por integração ou rejeição) se relaciona com o desfecho da revisão.

Os resultados estatísticos indicam uma diferença acentuada no tempo de análise. Os Pull Requests que foram aceites (MERGED) apresentaram uma mediana de apenas **27,88 horas**. Por outro lado, os PRs que acabaram por ser rejeitados (CLOSED) permaneceram em análise por uma mediana de **118,09 horas** — um valor aproximadamente quatro vezes superior ao grupo de sucesso.

O teste de Mann-Whitney resultou num p-valor de 0,00000, confirmando que a diferença temporal entre os grupos é estatisticamente significativa. Estes dados sugerem que a rapidez na análise e na resposta às revisões é um factor determinante para o sucesso da integração. PRs que sofrem atrasos prolongados no processo de revisão parecem ter uma tendência muito maior a serem abandonados ou formalmente rejeitados, possivelmente devido à perda de contexto do código ou à obsolescência da contribuição face à evolução do repositório principal.




Figure 3: Distribuição do Tempo de Análise por Status do PR

3.3 RQ03 - Descrição X Feedback Final

Esta questão de pesquisa investiga a relação entre o nível de detalhamento da descrição de um Pull Request (medido em quantidade de caracteres) e o seu status final. A hipótese inicial (H03) propunha que descrições mais extensas facilitariam a compreensão por parte do revisor, resultando numa maior taxa de aprovação.

Contudo, a análise dos dados revelou o cenário oposto. Os Pull Requests rejeitados ou abandonados (CLOSED) apresentaram uma mediana de 546,0 caracteres em suas descrições, um valor levemente superior à mediana de 514,0 caracteres observada nos PRs integrados com sucesso (MERGED).

O teste U de Mann-Whitney confirmou que essa diferença é estatisticamente significativa ($p = 0,00192 < 0,05$). Esse resultado sugere que descrições mais

longas não garantem, por si só, o sucesso do merge. Uma possível interpretação é que PRs que exigem descrições muito extensas geralmente tratam de problemas mais complexos, arquiteturas controversas ou pacotes de mudanças muito grandes, características que, naturalmente, aumentam a dificuldade da revisão e o risco de rejeição.




Figure 4: Distribuição do Tamanho da Descrição por Status do PR

3.4 RQ04 - Interações X Feedback Final

A quarta questão de pesquisa analisa o impacto do nível de interação social — mensurado pelo número de participantes e de comentários — no desfecho de um Pull Request.

Os dados coletados indicam que PRs rejeitados (CLOSED) tendem a gerar mais debates. A mediana de participantes em PRs com status CLOSED foi de 3,0, com uma mediana de 2,0 comentários. Em contrapartida, os PRs integrados com sucesso (MERGED) apresentaram uma mediana de 2,0 participantes e apenas 1,0 comentário. Ambas as métricas apresentaram diferença estatisticamente significativa de acordo com o teste U de Mann-Whitney ($p < 0,05$).

Esse comportamento sugere que contribuições que são prontamente aceitas costumam ser mais diretas e consensuais, exigindo pouca discussão (frequentemente envolvendo apenas o autor e um revisor que aprova as mudanças). Por outro lado, um volume maior de interações muitas vezes reflete discordâncias técnicas, dúvidas sobre a arquitetura da solução ou a necessidade de envolver mais desenvolvedores para chegar a um consenso, o que culmina, com maior frequência, no abandono ou na rejeição da proposta.




Figure 5: Distribuição do Número de Participantes por Status do PR

3.5 RQ05 - Tamanho X Número de Revisões

Para investigar a relação entre o tamanho do Pull Request e a quantidade de revisões realizadas, aplicou-se o coeficiente de correlação de Spearman nas métricas de arquivos modificados, linhas adicionadas e linhas removidas.

Os resultados apontaram correlações positivas e estatisticamente significativas ($p < 0,05$) para todas as métricas de tamanho, porém com intensidades de nível fraco. A maior correlação observada nesta dimensão foi em relação às linhas adicionadas (0,290), seguida pelo tamanho em arquivos (0,238) e pelas linhas removidas (0,168).

Esses dados indicam que, embora exista uma leve tendência de que contribuições maiores exijam mais revisões, o volume bruto de código não dita, de forma isolada e forte, a carga de revisão. Na prática, um PR extenso pode ser composto por código autogerado ou simples atualizações de dependências, exigindo menos esforço de análise do que alterações curtas, porém de alta complexidade arquitetural.




Figure 6: Correlação entre Linhas Adicionadas e Número de Revisões

3.6 RQ06 - Tempo X Número de Revisões

Esta questão de pesquisa explora se Pull Requests que permanecem abertos por maiores períodos de tempo são, consequentemente, submetidos a um número maior de revisões. A expectativa inicial (H02) era de que um maior tempo de análise refletisse discussões prolongadas e múltiplos ciclos de revisão.

No entanto, a correlação de Spearman calculada para esta métrica foi de apenas 0,096, sendo estatisticamente significativa ($p < 0,05$), mas classificada como muito fraca ou quase irrelevante.

Este resultado indica que o tempo de vida de um PR não é um bom preditor para a quantidade de revisões que ele receberá. A ausência de uma correlação forte sugere que muitos Pull Requests que ficam abertos por longos períodos (como as 118 horas observadas nos PRs rejeitados da RQ02) não estão necessariamente sob escrutínio ativo. Em vez disso, é provável que essas contribuições fiquem ociosas, esquecidas pelos mantenedores, ou bloqueadas aguardando ações externas que não geram novos registros formais de revisão.




Figure 7: Correlação entre Tempo de Análise e Número de Revisões

3.7 RQ07 - Descrição X Número de Revisões

A sétima questão de pesquisa buscou identificar se a quantidade de detalhes fornecida pelo autor na abertura do PR — medida pelo número de caracteres da descrição — possui impacto no volume de revisões exigidas.

A análise estatística indicou uma correlação de Spearman de 0,164, com significância estatística ($p < 0,05$). Embora válida, essa correlação é classificada como muito fraca.

Isso demonstra que o tamanho da descrição tem pouca ou nenhuma influência direta na quantidade de ciclos de revisão que o código sofrerá. Um PR com uma descrição exhaustiva pode, por um lado, esclarecer todas as dúvidas antecipadamente (reduzindo revisões) ou, por outro, indicar uma alteração de alta complexidade sistêmica (exigindo mais revisões). Como esses dois cenários opostos coexistem, a métrica isolada do tamanho do texto não se consolida como um bom indicador para prever a carga de code review.




Figure 8: Correlação entre Tamanho da Descrição e Número de Revisões

3.8 RQ08 - Interações X Número de Revisões

A última questão de pesquisa desta dimensão analisa como o envolvimento da comunidade — mensurado pelo número de participantes e de comentários — afeta a quantidade de revisões realizadas em um Pull Request.

Os resultados indicaram as correlações mais fortes de toda a Dimensão B. A métrica de participantes apresentou uma correlação de Spearman de 0,308, enquanto o número de comentários obteve 0,273. Ambas as correlações são estatisticamente significativas ($p < 0,05$).

Esses dados evidenciam uma relação direta e esperada: PRs que atraem mais participantes e geram extensas threads de comentários estão, inerentemente, sujeitos a um escrutínio mais rigoroso. O alto nível de interação geralmente denota debates sobre a implementação, sugestões de melhoria ou a identificação de defeitos por múltiplas partes, o que se traduz diretamente em um número maior de ciclos de revisão formal antes que a contribuição chegue ao seu desfecho.




Figure 9: Correlação entre Número de Participantes e Número de Revisões

4 Discussão

Nesta seção, os resultados estatísticos obtidos são confrontados com as hipóteses iniciais (H01 a H04) formuladas na introdução deste trabalho, permitindo uma análise crítica sobre as dinâmicas de code review nos repositórios analisados.

Análise da H01 (Tamanho do PR e Aceitação): A primeira hipótese pressupunha que Pull Requests maiores teriam menor probabilidade de aprovação devido ao esforço cognitivo exigido na revisão. No entanto, os resultados da RQ01 contrariam essa premissa. Os dados evidenciaram que os PRs integrados (MERGED) apresentaram, na mediana, um volume de código e de arquivos modificados ligeiramente superior aos rejeitados (CLOSED). Assim, a **H01 foi refutada**. Esse fenômeno sugere que, no universo de projetos populares, a rejeição está menos atrelada ao tamanho absoluto da contribuição e mais relacionada a problemas arquiteturais, falhas lógicas ou falta de alinhamento com o roadmap do projeto, independentemente de ser um PR de 10 ou 100 linhas.

Análise da H02 (Tempo de Análise e Revisões): A segunda hipótese sugeria que um maior tempo de análise indicaria maior complexidade e, consequentemente, mais revisões. Os dados da RQ02 e da RQ06 fornecem uma visão fragmentada sobre esta premissa, levando a uma **refutação parcial da H02**. Por um lado, o tempo de análise mostrou ser um forte preditor de falha: PRs rejeitados demoraram quase cinco vezes mais para serem encerrados do que os aprovados. Contudo, a baixíssima correlação de Spearman (0,096) entre tempo e número de revisões revela que esse período prolongado não reflete um trabalho ativo de code review. Na realidade, PRs abertos por muito tempo sofrem um "efeito de abandono", ficando ociosos na fila e eventualmente perdendo o momento de integração.

Análise da H03 (Descrição e Aprovação): A H03 estipulava que de-

scrições mais ricas facilitariam a aprovação. Os achados da RQ03 revelaram exatamente o oposto: PRs rejeitados possuíam descrições com maior número de caracteres do que os aceitos. Desta forma, a **H03 foi refutada**. Uma interpretação plausível é que mudanças triviais ou com alto consenso exigem pouca explicação. Em contrapartida, alterações polêmicas, que modificam comportamentos centrais do sistema, demandam extensas justificativas por parte do autor, sendo justamente essas as propostas com maior probabilidade de serem vetadas pelos mantenedores.

Análise da H04 (Interações Sociais e Revisão): A última hipótese afirmava que um maior volume de interações (participantes e comentários) estaria associado a revisões mais rigorosas e impactaria o resultado final. Os dados da RQ04 e da RQ08 sustentam fortemente essa afirmação, indicando que a **H04 foi corroborada**. O número de participantes foi a métrica com maior correlação positiva com a quantidade de revisões realizadas (0,308). Além disso, observou-se que PRs rejeitados geram consideravelmente mais comentários e atraem mais participantes do que os aprovados. Isso evidencia que o processo de code review atua como um filtro rigoroso: quando um código gera debates acalorados e exige múltiplas vezes, a tendência de rejeição aumenta substancialmente.

5 Conclusão

Este laboratório teve como objetivo investigar a dinâmica das atividades de code review em projetos de código aberto hospedados no GitHub. Por meio da extração e análise estatística de dados de Pull Requests, buscou-se compreender como atributos mensuráveis — como tamanho da contribuição, tempo de análise, nível de detalhamento da descrição e engajamento da comunidade — influenciam o sucesso da integração (merge) e a carga de revisões exigidas.

A análise dos resultados revelou que **o sucesso de um Pull Request está fortemente associado à agilidade do processo e ao consenso técnico**. Evidenciou-se que **PRs integrados com sucesso são resolvidos de forma consideravelmente mais rápida** e exigem menos debates do que propostas que acabam rejeitadas. **Curiosamente, características tradicionalmente associadas a uma maior dificuldade de aprovação, como o aumento do número de arquivos e de linhas modificadas, não se provaram impeditivos** no conjunto de dados analisado. De fato, as contribuições aceitas apresentaram, na mediana, um volume de código ligeiramente superior.

Por outro lado, o processo de rejeição mostrou-se caracterizado por um longo tempo de espera e por um alto ruído social. PRs que permanecem abertos por extensos períodos não indicam, necessariamente, que estão passando por um escrutínio rigoroso e contínuo, mas sim que caíram em um estado de ociosidade e abandono. Além disso, descrições mais extensas e um volume maior de comentários e participantes foram mais frequentes em propostas rejeitadas, sugerindo que o aumento da interação social frequentemente reflete discordâncias arquiteturais ou lógicas que culminam no fechamento da solicitação sem o merge.

Em suma, **conclui-se que o processo de code review transcende a**

mera verificação técnica do código fonte, sendo profundamente impactado por fatores temporais e sociais. Compreender o comportamento dessas métricas permite que equipes e desenvolvedores de projetos open source otimizem a submissão de suas propostas, buscando maior clareza, alinhamento técnico prévio e agilidade na resolução de feedbacks.

References

- [Bacchelli e Bird 2013]BACCHELLI, A.; BIRD, C. Expectations, outcomes, and challenges of modern code review. In: *Proceedings of the International Conference on Software Engineering (ICSE)*. [S.l.: s.n.], 2013.
- [Field 2013]FIELD, A. *Discovering Statistics Using IBM SPSS Statistics*. [S.l.]: Sage Publications, 2013.
- [GitHub 2026]GitHub. *About Pull Requests*. 2026. <https://docs.github.com/en/pull-requests>. Acesso em: 27 abr. 2026.
- [Goues et al. 2019]GOUES, C. L. et al. The many meanings of code review. *IEEE Software*, 2019.
- [Kalliamvakou et al. 2014]KALLIAMVAKOU, E. et al. The promises and perils of mining github. In: *Proceedings of the Mining Software Repositories (MSR)*. [S.l.: s.n.], 2014.
- [Kononenko et al. 2016]KONONENKO, O. et al. Investigating code review quality: Do people and participation matter? In: *ICSME*. [S.l.: s.n.], 2016.
- [Tsay, Dabbish e Herbsleb 2014]TSAY, J.; DABBISH, L.; HERBSLEB, J. Influence of social and technical factors for evaluating contribution in github. In: *Proceedings of the International Conference on Software Engineering (ICSE)*. [S.l.: s.n.], 2014.